

Daten für den Korpus vorbereiten

Mazedonisches Korpus · Kurzanleitung für die Tabellen · 19. September 2026

Worum es geht

Die Tabellen werden nicht nur von Menschen gelesen, sondern auch von einem Programm, das sie in die Korpusdatenbank einliest. Ein Mensch übersieht einen doppelten Leerschlag und erkennt `Југозапад` und `Југозапад` ohne Weiteres als dasselbe Wort. Das Programm sieht zwei verschiedene Werte und legt zwei verschiedene Kategorien an — still, ohne Fehlermeldung.

Alle Beispiele stammen aus Dateien, die schon geliefert wurden. Sie sind nicht als Kritik gemeint: so etwas passiert jedem, der mit Excel arbeitet. Sie zeigen nur, worauf das Programm empfindlich reagiert.

Faustregel: Zwei Werte bedeuten für das Programm nur dann dasselbe, wenn sie **zeichengenau** gleich geschrieben sind.

1. Identifikatoren

1.1 Jeder Text und jede Person bekommt einen Identifikator (ID). Eine ID ist kein Titel und keine laufende Nummer, sondern eine kurze Kennung, die den Eintrag ein für alle Mal bezeichnet.

1.2 Eine ID besteht nur aus Kleinbuchstaben `a–z`, Ziffern `0–9` und Unterstrichen. Keine Leerzeichen, keine Klammern, keine Umlaute, keine kyrillischen Buchstaben.

✗	Чорбаџи Теодос
✗	06 в) vasil iljoski
✓	iljoski_chorbadzhi_teodos_1937
✓	anton_panov

1.3 Sprechende IDs sind besser als Nummern. `panov_pechalbari_1936` sagt einem Menschen sofort, worum es geht; `4` sagt nichts. Und wenn ein Text dazukommt oder wegfällt, muss nichts umnummeriert werden. Bewährtes Muster: Texte `nachname_kurztitel_jahr`, Personen `vorname_nachname`.

1.4 Dieselbe ID steht in jeder Datei, die auf den Eintrag verweist. Das ist der wichtigste Punkt überhaupt. Wenn die Metadatentabelle `panov_pechalbari_1936` sagt, dann steht in der Annotationsdatei in der Spalte `text_id` genau derselbe Wert — nicht der Titel, nicht der Dateiname, nicht die Nummer.

In den bisherigen Lieferungen hiess derselbe Text an drei Stellen dreimal anders: `4` in der Spalte `Text_ID`, `06 6)` `anton panov – pechalbari_processed_FINAL` in der Spalte `text_id` und `Печалбари` in der Annotationsdatei. Damit lässt sich nichts automatisch verbinden.

1.5 Eine ID wird nie wieder geändert. Auch dann nicht, wenn sich ein Tippfehler eingeschlichen hat — fragt lieber kurz nach. Eine geänderte ID trennt den Text von allem, was auf ihn verweist.

1.6 Jede ID kommt genau einmal vor. Zwei Zeilen mit derselben ID sind ein Fehler, nicht eine Korrektur der anderen.

1.7 Titel und Dateiname gehen nicht verloren — sie bekommen eigene Spalten (`title`, `source_file`). Es sollen nur nicht drei verschiedene Dinge `text_id` heissen.

2. Werte in den Zellen

2.1 Ein Merkmal — ein Wort, immer gleich geschrieben. Legt euch für jede Spalte eine kleine Liste erlaubter Werte an und haltet euch daran. Kopiert den Wert aus der Liste, statt ihn neu zu tippen.

Spalte	Geschrieben als	Vom Programm gezählt als
Gender	М · М · М (mit Leerschlag)	3 verschiedene Geschlechter
Variety	Југозапад · Југозапад	2 verschiedene Dialektgebiete
Education	Средно · средно · Средно	3 verschiedene Abschlüsse

2.2 Keine Leerzeichen am Anfang oder Ende. Sie sind unsichtbar und trennen trotzdem. In Excel hilft `=TRIM(A1)`, um sie zu finden.

2.3 Eine Zelle — ein Wert. Wenn wirklich mehrere Werte nötig sind, trennt sie mit einem **Semikolon ohne Leerschlag** und immer gleich.

✗	Драма, Проза · SR/HR · EN/ PL · 1957, 1994
✓	drama;prose · sr;hr · en;pl

Bei Jahren noch besser: eine Spalte `year` für das erste Jahr und eine Spalte `year_note` für den Rest.

2.4 Keine Anmerkungen in der Wertzelle. Was in Klammern hinter einem Wert steht, ist eine Bemerkung und kein Wert. Dafür gibt es die Spalte `notes`.

	Spalte L3	Spalte notes
✗	NA (амб – Либан, Етиопија, Полска)	
✓	leer	ambassador to Lebanon, Ethiopia, Poland

Dasselbe gilt für Средно (гимназија) : der Abschluss gehört in education_level , die Schulart in education_note .

2.5 Eine leere Zelle heisst „nicht erfasst“. Schreibt nicht NA , - , ? oder keine Angabe — das sind für das Programm ganz normale Werte, und dann gibt es plötzlich eine Sprache namens „NA“.

2.6 Zahlen als Zahlen, nicht als Text. Jahreszahlen vierstellig: 1936 , nicht 1936 r . und nicht um 1936 . Eine Schätzung gehört als Bemerkung in notes .

2.7 Sprachen als ISO-639-1-Code, klein: mk , bg , sr , hr , ru , en , fr , de , ro , cs , sl , pl , bs , sq .

3. Spalten und Aufbau der Tabelle

3.1 Genau eine Kopfzeile, und zwar Zeile 1. Ab Zeile 2 nur noch Daten. Kein Titel über der Tabelle, keine Leerzeile dazwischen, keine Zwischenüberschriften mitten in den Daten.

3.2 Jede Spalte hat einen eigenen, eindeutigen Namen. Zwei Spalten dürfen nicht gleich heissen — in einer früheren Annotationsdatei gab es zweimal POS_Tag , und beim Einlesen überschrieb die eine die andere. Auch Text_ID und text_id sind keine unterschiedlichen Namen, sondern eine Falle: sie unterscheiden sich nur durch Gross- und Kleinschreibung.

3.3 Der Spaltenname sagt, was drinsteht. Die Spalte ud_valency enthielt in Wirklichkeit die Kopfposition des Tokens (head) — also die Nummer des Wortes, von dem dieses Wort syntaktisch abhängt. Wer den Namen liest, erwartet etwas anderes und liest die Daten falsch.

3.4 Spaltennamen auf Englisch, klein, mit Unterstrich: text_id , birth_year , place_of_birth . Keine Leerzeichen im Namen (Short Description → short_description).

3.5 Der Aufbau bleibt zwischen zwei Lieferungen gleich. Gleiche Spalten, gleiche Namen, gleiche Reihenfolge. Wenn eine Spalte wirklich dazukommen muss, sagt bitte kurz Bescheid — sonst bricht der Import.

3.6 Keine verbundenen Zellen, keine Formeln, keine Kommentare im Excel-Sinn. Verbundene Zellen werden beim Export zu einer Zelle mit Inhalt und mehreren leeren.

3.7 Farbe ist keine Information. Eine gelb markierte Zelle bedeutet für das Programm gar nichts — die Markierung verschwindet beim Export spurlos. Wenn die Farbe etwas heissen soll („unsicher“, „noch prüfen“), macht daraus eine eigene Spalte, zum Beispiel status mit den Werten checked und uncertain .

3.8 Eine Zeile — ein Eintrag. Eine Person, ein Text, ein Token. Nicht zwei Personen in einer Zeile, und nicht eine Person über zwei Zeilen verteilt.

4. Dateien und Kodierung

4.1 Kurze Dateinamen aus lateinischen Kleinbuchstaben. Am besten genau die ID plus die Endung.

✗	06 6) anton panov – pechalbari_processed_FINAL.xlsx
✓	panov_pechalbari_1936.xlsx

Keine Leerzeichen, keine Klammern, keine laufenden Nummern vorne, kein _FINAL , _neu , _v2 , _korrigiert . Die Version steht im Datum der Lieferung, nicht im Namen.

4.2 Schickt lieber .xlsx als .csv . In einer CSV-Datei muss jede Zelle, die ein Komma enthält, in Anführungszeichen stehen. Genau daran ist eine Lieferung gescheitert:

Дијалектен – крушевски говор (западно наречје, прилепско-битолски говори)

Das Komma in der Mitte zerlegte die Zelle in zwei, und alles rechts davon rutschte eine Spalte weiter: die Jahreszahl landete in der Spalte Source . In .xlsx kann das nicht passieren.

4.3 Wenn es doch CSV sein muss: beim Speichern „CSV UTF-8“ wählen (nicht „CSV Windows“ oder „CSV Macintosh“), Trennzeichen Komma.

4.3a Wenn statt kyrillischer Buchstaben ЂЃЌЌЃЌ dasteht, ist die Datei in Ordnung — Excel liest sie nur falsch. Excel nimmt bei einer .csv nicht von selbst UTF-8 an. Zwei Wege:

Weg	So geht es
Die Datei öffnen	Excel nicht per Doppelklick starten, sondern Daten → Aus Text/CSV und dort als Dateiusprung Unicode (UTF-8) wählen.
Gar nicht erst haben	Mit .xlsx arbeiten. Dort steckt die Kodierung in der Datei, und es gibt nichts einzustellen.

4.3b Kommas im Text sind kein Problem, solange die Zelle in Anführungszeichen steht. So sieht eine korrekt geschriebene Zeile aus:

majski_ilinden_1923,Илинден,nikola_kirov_majski,literature,drama,dialectal,"krushevski govor zapadno narechje, prilepsko-bitolski govori",192

Das Komma steht innerhalb der Anführungszeichen und zählt darum nicht als Spaltengrenze. Excel und jedes andere Programm schreiben das beim Speichern von selbst so — man muss nur beim Speichern das richtige Format wählen und die Anführungszeichen hinterher nicht von Hand entfernen.

4.4 Lateinische und kyrillische Zwillingsbuchstaben nicht mischen. Manche Buchstaben sehen identisch aus, sind aber verschiedene Zeichen:

Sieht aus wie	Ist aber	Kommt vor in
Ј	lateinisches J	Југозапад , Скопје , Дијалектен
М	lateinisches M	М in der Spalte Gender
а е о р с х	а е о р с х	überall dort, wo jemand die Tastatur gewechselt hat

Das passiert meistens beim Tippen mit umgeschalteter Tastatur. Prüfen lässt es sich mit Suchen & Ersetzen: nach dem lateinischen `j` suchen — in einem mazedonischen Wort hat es nichts zu suchen.

4.5 Beim Exportieren das richtige Blatt erwischen. Eine Lieferung hiess `..._Metadata_Speakers_New.csv`, enthielt aber Zeile für Zeile die Dokumententabelle. Öffnet die exportierte Datei noch einmal und schaut hinein, bevor ihr sie verschickt.

4.6 Eine Datei — eine Tabelle. Nicht mehrere Blätter mit Daten in einer Arbeitsmappe.

5. Sprache

5.1 Das Korpus ist englisch, das Material ist mazedonisch. Oberfläche, Spaltennamen und alle Kategorien sind auf Englisch, damit auch Kolleginnen und Kollegen damit arbeiten können, die kein Mazedonisch lesen.

Mazedonisch bleibt: der Text selbst, die Wortformen, die Lemmata, die Titel der Werke, die Namen der Personen. *Englisch wird:* Genre, Textsorte, Varietät, Geschlecht, Bildungsabschluss, Religion, Dialektgebiet, Ortsnamen, alle Bemerkungen.

Spalte	✗	✓
data_genre	Литература	literature
text_genre	Драма	drama
variety	Стандарден	standard
sex	М	male
religion	Православен	Orthodox
education_level	Факултет	tertiary
dialect_region	Југозапад	southwest
title	—	Печалбари bleibt mazedonisch
name	—	Антон Панов bleibt mazedonisch

5.2 Ortsnamen lateinisch und in ihre Teile zerlegt. Statt `с. Стар Дојран, Општина Дојран` drei Spalten: `place_of_birth` = `Star Dojran`, `place_type` = `village`, `municipality` = `Dojran`. So lässt sich fragen, wer alles aus einer bestimmten Gemeinde stammt.

5.3 Eine feste Umschrift. Für die IDs und die lateinischen Ortsnamen gilt immer dieselbe Tabelle: `ж` → `zh`, `ч` → `ch`, `ш` → `sh`, `џ` → `dzh`, `ѣ` → `gj`, `ќ` → `kj`, `љ` → `lj`, `њ` → `nj`, `с` → `dz`, `ј` → `j`. Die Umschrift muss nicht schön sein — sie muss immer gleich sein.

Checkliste vor dem Verschicken

- ☐ Die Datei heisst wie die ID, klein, lateinisch, ohne Leerzeichen
- ☐ Ich habe die exportierte Datei noch einmal geöffnet und hineingeschaut
- ☐ Zeile 1 ist die Kopfzeile, ab Zeile 2 nur Daten, keine Leerzeilen dazwischen
- ☐ Jede Spalte heisst anders, und der Name sagt, was drinsteht
- ☐ Jede Zeile hat eine ID, jede ID kommt genau einmal vor
- ☐ Die IDs sind dieselben wie in der Metadamentabelle — Zeichen für Zeichen
- ☐ Autofilter über die Spalten gelegt und die Wertlisten angeschaut: keine Dubletten wie `Средно` / `средно` / `Средно`
- ☐ Kein `NA`, kein `-`, kein `?` — nicht Erfasstes bleibt leer
- ☐ Keine Anmerkungen in Klammern in einer Wertzelle; sie stehen in `notes`
- ☐ Nach lateinischem `j` und `M` in mazedonischen Wörtern gesucht
- ☐ Metadaten auf Englisch, nur Text, Titel und Namen mazedonisch
- ☐ Keine verbundenen Zellen, keine Farbe als Bedeutung
- ☐ Als `.xlsx` gespeichert (oder als CSV UTF-8, falls es CSV sein muss)

Im Zweifel lieber einmal kurz nachfragen, als raten. Eine Frage kostet fünf Minuten, eine falsch verstandene Spalte kostet einen Tag.