

Подготовка данных для корпуса

Македонский корпус · краткая инструкция по таблицам · 19 сентября 2026

О чём речь

Таблицы читают не только люди, но и программа, которая загружает их в базу корпуса. Человек не замечает лишнего пробела и без труда понимает, что `Југозапад` и `Југозапад` — одно и то же слово. Программа видит два разных значения и заводит две разные категории — молча, без сообщения об ошибке.

Все примеры взяты из уже присланных файлов. Это не упрёк: так получается у всех, кто работает в Excel. Они просто показывают, к чему программа чувствительна.

Главное правило: два значения совпадают для программы только тогда, когда они написаны **посимвольно одинаково**.

1. Идентификаторы

1.1 У каждого текста и каждого человека есть идентификатор (ID). Это не заголовок и не порядковый номер, а короткая метка, которая обозначает запись раз и навсегда.

1.2 В идентификаторе только строчные латинские буквы `a–z`, цифры `0–9` и подчёркивания. Без пробелов, скобок и кириллицы.

✗	Чорбаџи Теодос
✗	06 в) vasil iljoski
✓	iljoski_chorbadzhi_teodos_1937
✓	anton_panov

1.3 Говорящий идентификатор лучше номера. `panov_pecalbari_1936` сразу понятен человеку, а `4` не говорит ничего. И если текст добавится или выпадет, ничего не придётся перенумеровывать. Рабочая схема: тексты — `фамилия_краткое_название_год`, люди — `имя_фамилия`.

1.4 Один и тот же идентификатор стоит во всех файлах, которые ссылаются на запись. Это самый важный пункт. Если в таблице метаданных написано `panov_pecalbari_1936`, то в файле аннотаций в колонке `text_id` стоит ровно то же самое — не заголовок, не имя файла, не номер.

В присланных файлах один и тот же текст назывался по-разному в трёх местах: `4` в колонке `Text_ID`, `06 в)` `anton panov – pecalbari_processed_FINAL` в колонке `text_id` и `Печалбари` в файле аннотаций. Связать это автоматически невозможно.

1.5 Идентификатор потом не меняют. Даже если в нём опечатка — лучше спросить. Изменённый идентификатор отрывает текст от всего, что на него ссылается.

1.6 Каждый идентификатор встречается ровно один раз. Две строки с одинаковым ID — это ошибка, а не исправление одной другой.

1.7 Заголовок и имя файла не теряются — у них свои колонки (`title`, `source_file`). Просто не нужно, чтобы три разные вещи назывались `text_id`.

2. Значения в ячейках

2.1 Один признак — одно слово, всегда написанное одинаково. Заведите для каждой колонки небольшой список допустимых значений и держитесь его. Копируйте значение из списка, а не набирайте заново.

Колонка	Написано как	Программа считает это
Gender	М · М · М (с пробелом)	тремя разными полами
Variety	Југозапад · Југозапад	двумя разными диалектными зонами
Education	Средно · средно · Средно	тремя разными образованиями

2.2 Никаких пробелов в начале и конце. Их не видно, но они разводят значения. В Excel помогает `=СЖПРОБЕЛЫ(А1)` (в английской версии `=TRIM(A1)`).

2.3 Одна ячейка — одно значение. Если значений всё же несколько, разделяйте их **точкой с запятой без пробела** и всегда одинаково.

✗	Драма, Проза · SR/HR · EN/ PL · 1957, 1994
✓	drama;prose · sr;hr · en;pl

С годами ещё лучше: колонка `year` для первого года и `year_note` для остальных.

2.4 Никаких примечаний в ячейке со значением. То, что стоит в скобках после значения, — это комментарий, а не значение. Для него есть колонка `notes`.

	Колонка L3	Колонка notes
✗	NA (амб — Либан, Етиопија, Полска)	
✓	пусто	ambassador to Lebanon, Ethiopia, Poland

То же с `Средно (гимназија)`: уровень образования идёт в `education_level`, тип школы — в `education_note`.

- 2.5 Пустая ячейка значит «не записано». Не пишите `NA`, `-`, `?` или `нет данных` — для программы это обычные значения, и в корпусе вдруг появляется язык под названием «NA».
- 2.6 Числа — числами, а не текстом. Год четырьмя цифрами: `1936`, а не `1936 г.` и не `около 1936`. Предположение идёт в `notes`.
- 2.7 Языки — кодами ISO 639-1, строчными: `mk`, `bg`, `sr`, `hr`, `ru`, `en`, `fr`, `de`, `ro`, `cs`, `sl`, `pl`, `bs`, `sq`.
3. Колонки и устройство таблицы
- 3.1 Ровно одна строка заголовков, и это строка 1. Со строки 2 — только данные. Никаких названий над таблицей, пустых строк между ними и подзаголовков посреди данных.
- 3.2 У каждой колонки своё уникальное имя. Две колонки не могут называться одинаково: в одном из файлов аннотаций `POS_Tag` встречалась дважды, и при загрузке одна затирала другую. `Text_ID` и `text_id` — тоже не разные имена, а ловушка: они отличаются только регистром.
- 3.3 Имя колонки говорит, что в ней лежит. Колонка `ud_valency` на самом деле содержала номер вершины (`head`) — того слова, от которого синтаксически зависит данное. Кто читает имя, ждёт совсем другого и понимает данные неверно.
- 3.4 Имена колонок — по-английски, строчными, через подчёркивание: `text_id`, `birth_year`, `place_of_birth`. Без пробелов в имени (`Short Description` → `short_description`).
- 3.5 Структура не меняется от посылки к посылке. Те же колонки, те же имена, тот же порядок. Если колонку действительно нужно добавить — напишите, иначе импорт сломается.
- 3.6 Никаких объединённых ячеек, формул и примечаний Excel. Объединённая ячейка при экспорте превращается в одну заполненную и несколько пустых.
- 3.7 Цвет — не информация. Жёлтая заливка для программы не значит ничего и при экспорте исчезает бесследно. Если цвет что-то означает («неточно», «проверить») — сделайте отдельную колонку, например `status` со значениями `checked` и `uncertain`.
- 3.8 Одна строка — одна запись. Один человек, один текст, один токен. Не два человека в одной строке и не один человек на две строки.

4. Файлы и кодировка

4.1 Короткие имена файлов из строчной латиницы. Лучше всего — ровно идентификатор плюс расширение.

✗	06 6) anton panov – pecalbari_processed_FINAL.xlsx
✓	panov_pecalbari_1936.xlsx

Без пробелов, скобок и номеров в начале, без `_FINAL`, `_new`, `_v2`, `_исправленный`. Версия — это дата письма, а не имя файла.

4.2 Лучше присылать `.xlsx`, а не `.csv`. В CSV каждая ячейка с запятой внутри должна быть в кавычках. Именно на этом сломалась одна из посылок:

Дијалектен – крушевски говор (западно наречје, прилепско-битолски говори)

Запятая в середине разорвала ячейку надвое, и всё правее съехало на колонку: год оказался в колонке `Source`. В `.xlsx` такого не бывает.

4.3 Если всё же CSV: при сохранении выбирайте «CSV UTF-8» (а не «CSV Windows» или «CSV Macintosh»), разделитель — запятая.

4.3a Если вместо кириллицы видно `ЉѢЉѢЉѢ`, с файлом всё в порядке — это Excel читает его неверно. Открывая `.csv`, Excel не догадывается, что там UTF-8. Два выхода:

Способ	Что делать
Открыть файл правильно	Не двойным щелчком, а через <i>Данные</i> → <i>Из текста/CSV</i> , и там в поле «Источник файла» выбрать Юникод (UTF-8).
Не сталкиваться вовсе	Работать с <code>.xlsx</code> : кодировка зашита внутри файла, настраивать нечего.

4.3b Запятые внутри текста не мешают, если ячейка взята в кавычки. Вот как выглядит правильно записанная строка:

majski_ilinden_1923,Илинден,nikola_kirov_majski,literature,drama,dialectal,"krushevski govor zapadno narechje, prilepsko-bitolski govori",1923

Запятая стоит внутри кавычек и поэтому не считается границей колонки. Excel и любая другая программа пишут так сами при сохранении — нужно лишь выбрать правильный формат и не удалять кавычки потом вручную.

4.4 Не смешивать латинские и кириллические буквы-близнецы. Некоторые буквы выглядят одинаково, но это разные символы:

Выглядит как	А на самом деле	Встречалось в
Ј	латинская J	Југозапад, Скопје, Дијалектен
М	латинская M	М в колонке Gender
а е о р с х	а е о р с х	везде, где переключали раскладку

Проверить можно поиском и заменой: поискать латинскую `j` — в македонском слове ей делать нечего.

4.5 При экспорте выбирайте нужный лист. Одна посылка называлась `...Metadata_Speakers_New.csv`, а внутри строка в строку лежала таблица документов. Откройте выгруженный файл ещё раз и загляните внутрь, прежде чем отправлять.

4.6 Один файл — одна таблица. Не несколько листов с данными в одной книге.

5. Язык

5.1 Корпус англоязычный, материал — македонский. Интерфейс, имена колонок и все категории — на английском, чтобы с корпусом могли работать и те, кто не читает по-македонски.

Македонским остаётся: сам текст, словоформы, леммы, названия произведений, имена людей. По-английски: жанр, тип текста, разновидность языка, пол, образование, религия, диалектная зона, географические названия, все примечания.

Колонка	✗	✓
data_genre	Литература	literature
text_genre	Драма	drama
variety	Стандарден	standard
sex	М	male
religion	Православен	Orthodox
education_level	Факултет	tertiary
dialect_region	Југозапад	southwest
title	—	Печалбари остаётся как есть
name	—	Антон Панов остаётся как есть

5.2 Географические названия — латиницей и по частям. Вместо с. Стар Дојран, Општина Дојран три колонки: place_of_birth = Star Dojran, place_type = village, municipality = Dojran. Тогда можно спросить, кто родился в определённой общине.

5.3 Одна и та же транслитерация всегда. Для идентификаторов и латинских названий: ж → zh, ч → ch, ш → sh, џ → dzh, ђ → gj, ќ → kj, љ → lj, њ → nj, s → dz, j → j. Транслитерация не обязана быть красивой — она обязана быть одинаковой.

Чеклист перед отправкой

- ☐ Файл назван как идентификатор: строчная латиница, без пробелов
- ☐ Я открыл выгруженный файл и заглянул внутрь
- ☐ Строка 1 — заголовки, со строки 2 только данные, пустых строк нет
- ☐ Все колонки названы по-разному, и имя говорит, что внутри
- ☐ У каждой строки есть ID, и каждый ID встречается один раз
- ☐ ID те же самые, что в таблице метаданных — символ в символ
- ☐ Поставил автофильтр и просмотрел списки значений: нет дублей вроде Средно / средно / Средно
- ☐ Нет NA, —, ? — незаполненное остаётся пустым
- ☐ Нет примечаний в скобках внутри значения — они в notes
- ☐ Поиском проверил латинские j и M в македонских словах
- ☐ Метаданные по-английски; по-македонски только текст, названия и имена
- ☐ Нет объединённых ячеек и цвета в значении признака
- ☐ Сохранил как .xlsx (или как CSV UTF-8, если нужен CSV)

Если сомневаетесь — лучше спросить, чем угадывать. Вопрос стоит пять минут, неправильно понятая колонка — рабочего дня.